

Аналитический отчет

Цель исследования: с помощью данных о покупках клиентов и их социально-демографических признаках проанализировать эффективность уже проведённых ранее маркетинговых кампаний и выявить факторы, способные повысить продажи.

В ходе проведения исследования были проведены:

- предобработка имеющихся данных магазина спортивных товаров;
- использование бинарной классификации, для заполнения потерянных данных;
- проведения А/В-тестирования для определения эффективности маркетинговой кампании;
- разбиение аудитории на кластеры, для дальнейшей эффективной персональной работы с каждым;
- построение модели склонности к покупке.

Исследовательский анализ данных

Данные представлены в базе данных, содержащей следующие таблицы:


- **personal_data** — ID клиентов, их пол, возраст, образование, страна и город проживания;
- **personal_data_coeffs** — данные с персональными коэффициентами клиентов, которые рассчитываются по некоторой закрытой схеме;
- **purchases** — данные о покупках: ID покупателя, название товара, цвет, стоимость, гендерная принадлежность потенциальных покупателей товара, наличие скидки (поле `base_sale`. Значение 1 соответствует наличию скидки на момент покупки) и дата покупки.

Также отдельный файл **personal_data.csv.gz**, в котором некоторые данные утеряны и требуют восстановления.

Подготовка и очистка данных.

- пропуски в столбце `product_sex` заменены на «2», подразумевая товар `unisex`;
- пропуски в столбце `colour` были заменены на «нет данных». Там, где в цветах присутствовал символ «/», было заменено на «в нескольких цветах». Также все варианты цветов с приставками (темно-, светло-, ярко-, бледно- и другие), различные оттенки были скорректированы и приведены к более стандартной палитре, где в итоге оказалось 12 позиций;
- был создан столбец `name_product`, где отображается первое слово из столбца `product`, в котором очень много информации и с которым сложно работать в дальнейшем;
- добавлен столбец `brand`, в котором отображается бренд товара. Редко встречающиеся бренды были объединены в категорию «другое»;
- добавлен столбец `category_product`, в котором товары отсортированы по определенным категориям (одежда, обувь, спортивный инвентарь, аксессуары/ухож/карты, отдых/туризм, спортивное питание);
- в столбце `education`, там, где возраст клиентов был меньше 22 лет, значение «высшее» было заменено на «среднее»;

- в столбце cost, есть значительные выбросы (Иллюстрация 1). Но после оценки рынка, было принято решение оставить эти значения, так как стоимость оправдана;
- также были отсеяны клиенты, возраст которых меньше 14 лет и клиенты старше 70 лет (Иллюстрация 2).



Иллюстрации 1, 2. Визуализации (boxplot) распределения cost и age.

Бинарная классификация

Для восстановления данных с полом клиента (gender) использовалась бинарная классификация. В моделях использовались следующие признаки:

- категориальные – education, закодированы с помощью OneHotEncoder;
- числовые - age, city, country, personal_coef, стандартизированы с помощью StandardScaler.

Значения метрик для моделей прогнозирования представлены в Таблице 1.

Таблица 1.

Модель	F1-score	Precision	Recall	Accuracy
Логистическая регрессия	0,98	0,96	1,0	0,98
Дерево решений	1,0	1,0	1,0	1,0
Случайный лес	0,99	0,99	0,99	0,99

В результате, в качестве заполнения пропусков, использовалась модель дерева решений. Файл с заполненными данными сохранен в «Предсказание пола покупателей.csv».

A/B – тестирование

Кампания проводилась в период с 5-го по 16-й день, ID участвовавших в ней пользователей содержатся в файле `ids_first_company_positive.txt`. Эта кампания включала в себя предоставление персональной скидки 5 000 клиентов через email-рассылку. Помимо людей, которым предлагалась персональная скидка, были отобраны люди со схожими социально-демографическими признаками и покупками, которым скидку не предложили (файл `ids_first_company_negative.txt`).

В тестовой и контрольной группах предварительно убираем дубликаты и ID, которые попали и в ту, и в другую группу.

Используемые метрики, для оценки тестирования:


- средний чек (так как отсутствует идентификатор одного заказа можно предположить, что один день = одному чеку для конкретного клиента);
- выручка;
- число покупок на клиента;
- количество людей с повторными покупками.

Результаты тестирования представлены в Таблице 2.


Таблица 2.

Группа	Средний чек	Выручка	Число покупок на клиента	Количество людей с повторными покупками
test	10590	131190662	5,23	3381
control	10071	109621740	4,00	2945


Различия в метриках оценивались с помощью статистических тестов. Так для значений среднего чека, выручки, и числа покупок распределение ненормальное (Иллюстрации 3-8), использовался тест Манна-Уитни. Так как в случае количества людей с повторными покупками мы считаем долю, то можем использовать Z-тест. Результаты представлены в Таблице 3.



Иллюстрации 3,4. Распределения среднего чека тестовой и контрольной выборок.



Иллюстрации 5, 6. Распределения выручки тестовой и контрольной выборок.



Иллюстрации 7, 8. Распределения числа покупок тестовой и контрольной выборок.

Следует дополнительно изучить 16 день акции, так как количество покупок только в этот день в контрольной группе гораздо выше (Иллюстрация 9).




Иллюстрация 9. Динамика покупок по группам.

Таблица 3.

Метрика	Тест	p-value
Средний чек	Манна-Уитни	2.34e-10
Выручка	Манна-Уитни	4.89e-39
Число покупок на клиента	Манна-Уитни	4.93e-86
Количество людей с повторными покупками	Z-тест	3.06e-32

Различия в метриках в тестовой и контрольной группах статистически значимы.

Бизнес-рекомендация:

Не смотря на наличие скидки, средний чек вырос, это означает, что люди покупают больше товаров либо переходят в более дорогой сегмент. Число покупок и количество повторных покупок тоже больше, следовательно, акция привлекательно влияет на клиентов, провоцируя их покупать больше и возвращаться. Общая выручка выросла почти на 20% это прямое подтверждение того, что кампания эффективна. Перед тем как внедрить кампанию на всю аудиторию нужно:

- протестить данную кампанию на более широкую аудиторию (или другой сегмент), увеличить период и проверить стабилен ли положительный эффект;
- если средний чек вырос, то возможно стоит скорректировать размер скидки, сделать его меньше, тем самым снизить затраты, но сохранить заинтересованность клиентов в покупке;
- выделить категории покупателей, которые откликнулись на данную кампанию и запускать ее более персонализировано;
- обратить внимание на клиентов, которые давно не совершали покупки и на тех, кто покупает часто, но с невысоким чеком и попробовать реализовать акцию на них;
- перед масштабированием посчитать ROI (на данный момент это невозможно, так как не знаем затраты на рекламу).

Общая рекомендация – продолжать и масштабировать кампанию с дальнейшей сегментацией и оптимизацией скидки.

Кластеризация

Так как данные смешанные, были принято решение использовать для кластеризации метод K-Prototypes. Числовые признаки стандартизированы с помощью StandardScaler, категориальные признаки для t-SNE закодированы с помощью LabelEncoder.

Для кластеризации использовались следующие признаки: category_product, cost, base_sale, gender, age, personal_coef.

Количество кластеров определялось по методу локтя, методу силуэта (Иллюстрации 10, 11).




Иллюстрация 10. Метод локтя




Иллюстрация 11. Метод силуэта

Согласно графикам количество кластеров равно 7.





Иллюстрация 12. Визуализации кластеров ($k = 7$) методом t-SNE для кластеризации методом K-Prototypes.


Значения метрики Silhouette для данного метода = 0,44.

Визуализации распределения признаков по кластерам представлены на Иллюстрациях 13-17.



Иллюстрации 13, 14. Распределения возраста и стоимости товара по кластерам.

Стоит отметить, что самые молодые клиенты, чей возраст от 16 до 32 лет, находятся в 4 кластере. Товары с самой высокой стоимостью во 2 кластере.



Иллюстрации 15-16. Доли клиентов, воспользовавшихся скидкой и распределение пола клиентов по кластерам.




Иллюстрация 17. Категории продуктов, распределенные по кластерам.

Средние значения по кластерам приведены в таблице 4.

Таблица 4.

Кластер	Стоймость	Наличие скидки	Пол	Возраст	Персональный коэффициент	Категория продуктов
0	2819,98	0,52	0,00	42	0,51	одежда
1	7044,72	0,36	1,00	39	0,44	обувь
2	14704,27	0,12	0,67	38	0,46	спортивный инвентарь
3	2181,93	0,26	0,58	40	0,47	аксессуары/уход/ карты
4	4639,50	0,28	0,81	24	0,34	отдых/туризм
5	4876,66	0,35	0,00	41	0,51	обувь
6	3517,96	0,41	1,00	40	0,44	одежда

Описание кластеров:

- 0 - женская одежда со скидками;
- 1 - обувь с высоким средним чеком для мужчин среднего возраста, реагирующих на скидки, но не сильно;
- 2 - дорогие спортивные товары для мужчин и женщин, не реагирующих на скидки (премиальные клиенты);
- 3 - товары с низким средним чеком из категории аксессуары/уход для мужчин и женщин, покупаемые без скидок;
- 4 - товары для активного отдыха и туризма, для молодежи, преимущественно для мужчин, не очень интересующихся скидками;
- 5 - обувь для женщин средней стоимости, скидки важны, но не критично;
- 6 - мужская одежда средней стоимости, со скидками.

Рекомендации:

- 0 - всевозможные скидочные кампании, персональные подборки из категории одежда, акции для увеличения количества товара в чеке (покупаешь 3 вещи - получаешь скидку);
- 1 - сезонные предложения на обувь, скидка на вторую пару обуви, персональные подборки;
- 2 - персональные предложения и пакеты, как для премиальных клиентов, персональная подборка товаров, не предлагать скидок так как они не нужны;
- 3 - предлагать покупать сопутствующий товар, предлагать дополнить корзину еще каким-то продуктом, предлагать товар по более дорогой цене или улучшенной версии, тем самым повышая средний чек;
- 4 - комплекты и сеты для активного отдыха, подборки товаров для путешествий, делать рекомендации на основе интересов;
- 5 - сезонные предложения на обувь, скидка на вторую пару, подборки «тренд сезона»;
- 6 - увеличивать средний чек, путем предложения акций 2+1, акции «собери себе образ», распродажи.

Построение модели склонности к покупке.

В качестве таргета использовались:

1. Категория товара;
2. Склонность клиента принять участие в акции.

Целями построения моделей были, в первом случае - предсказать какой товар с наибольшей вероятностью выберет клиент, во втором - насколько клиент склонен участвовать в акциях. Это позволит сегментировать клиентов и в дальнейшем делать персональные предложения.

1) Модели предсказания категории товара, которую выберет клиент представлены в Таблице 5. В моделях использовались следующие признаки:

- категориальные – colour, education, brand, закодированы с помощью OneHotEncoder;
- числовые - cost, product_sex, base_sale, gender, age, personal_coef стандартизированы с помощью StandardScaler.

Разделение на тестовую и контрольную выборку производилось с помощью кросс-валидации. Обучение проводилось на всех данных.

Таблица 5.

Модель	Accuracy
Логистическая регрессия	0,60
Дерево решений	0,86
Случайный лес	0,82
Многослойный перцептрон	0,76

Наилучшими моделями в данном случае оказались модели дерева решений и случайный лес. Это можно объяснить тем, что такие модели хорошо работают с нелинейными зависимостями и категориальными переменными и не требуют сложного тюнинга.

Данные по продуктам были достаточно размазаны и разнообразны. Признак category_product был создан вручную на основании текстового описания товара. Нельзя точно сказать, что категории были максимально разделены правильно, но это в любом случае упростило работу модели. Также нужно учесть, что один и тот же клиент может купить совершенно разные товары, поэтому сложно полностью предсказать его поведение, поэтому данные метрики являются неплохими для данной задачи.

2) Модели предсказания склонности клиента принять участие в акции представлены в Таблице 6. В этом случае для обучения моделей использовались данные кампаний, проводимые на жителях города 1134 (представляющие собой баннерную рекламу на билбордах: скидка всем каждое 15-е число месяца (15-й и 45-й день в нашем случае)). В качестве тестовой выборки использовались все дни до 45, в качестве контрольной оставшиеся дни, начиная с 45. В моделях использовались следующие признаки:

- категориальные – category_product, brand, закодированы с помощью OneHotEncoder;

- числовые - cost, base_sale, gender, age, personal_coef стандартизированы с помощью StandardScaler.

Для устранения дисбаланса классов использовалось SMOTE (категории 0 – 66%, категории 1 – 34%)

Таблица 6.

Модель	F1-score	Precision	Recall	ROC-AUC	Accuracy
Логистическая регрессия	0,44	0,39	0,51	0,52	0,51
Дерево решений	0,46	0,45	0,47	0,57	0,58
Случайный лес	0,43	0,46	0,41	0,59	0,60
Многослойный перцептрон	0,46	0,41	0,52	0,55	0,54
CatBoost (Categorical Boosting)	0,53	0,40	0,82	0,56	0,46

Низкое качество моделей скорее всего связано с небольшим дисбалансом данных, также метрика Accuracy не совсем информативна в данном случае. Возможно, модели недостаточно данных, чтобы предсказать будет ли участвовать клиент в акции или нет. Наилучшей моделью среди представленных является CatBoost, метрика Recall у нее достаточно высокая (ловит 82% целевых клиентов), также неплохое значение F1, но низкое значение Precision (среди предсказанных «1», только 40% настоящие). Точность ниже, но охватывает нужных клиентов. Если у нашей маркетинговой кампании не стоит вопрос в стоимости привлечении каждого клиента (а это так, так как это баннерная реклама, а не персональная рассылка), то можно использовать.